



UNIVERSIDAD DE SAN CARLOS DE GUATEMALA
ESCUELA DE CIENCIAS FÍSICAS Y MATEMÁTICAS

REDES NEURONALES DE APRENDIZAJE AUTOMÁTICO PARA LA INFERENCIA DE MODELOS FÍSICOS

Anteproyecto de Año de Prácticas elaborado por
Cesar Alejandro Barillas Segura
presentada ante el Departamento de Física

Supervisado por
Dr. Giovanni Ramírez García (ECFM-USAC)

Guatemala, Marzo de 2024

1. Descripción general de la Institución

La Universidad de San Carlos de Guatemala (USAC) es la institución de educación superior estatal, autónoma, con cultura democrática, con enfoque multi e intercultural, vinculada y comprometida con el desarrollo científico, social, humanista y ambiental, con una gestión actualizada, dinámica, efectiva y con recursos óptimamente utilizados para alcanzar sus fines y objetivos. Es la universidad más antigua de Guatemala, habiendo sido fundada el 31 de enero de 1676. El campus central se encuentra ubicado en el Departamento de Guatemala, Ciudad Universitaria 11 Avenida, Zona 12. Su lema es *Id y enseñad a todos*.

La Escuela de Ciencias Físicas y Matemáticas (ECFM) es una escuela no facultativa formada en el año 2009 en el evento CONVERGENCIA. Actualmente, la escuela cuenta con la carrera de Licenciatura en Física Aplicada y Licenciatura en Matemática Aplicada. La escuela cuenta también con un Instituto dedicado a la investigación de las ciencias físicas y matemáticas (IFIM) el cual ha presentado diversas investigaciones y publicado una variedad de artículos relacionados con la divulgación del conocimiento de las ciencias.

El IFIM es la unidad de la ECFM que promueve y realiza estudios avanzados en áreas científicas fundamentales y aplicadas de las ciencias físicas y matemáticas. Las áreas y líneas de investigación del Instituto son

1. Física de altas energías, cosmología y astrofísica: Física de partículas, Astrofísica de rayos gamma.
2. Ciencias no lineales y sistemas complejos: Materia condensada, Modelos numéricos del clima, Modelos matemáticos en ciencias de la salud.
3. Geofísica: Geodesia aplicada a la tectónica.
4. Física experimental: Detección de partículas e instrumentación electrónica, Redes de sensores.
5. Física de radiaciones: Control de calidad en radioterapia.

Además, el Instituto realiza actividades de difusión y divulgación, Seminarios científicos, Conferencias de divulgación científica y también Talleres y cursos cortos.

2. Descripción del grupo de trabajo

La Física de Materia Condensada es un área muy amplia e interesante. Mediante el estudio de las propiedades fundamentales de la materia se pueden observar fenómenos interesantes que permiten el desarrollo de nuevas tecnologías. En años recientes la relación entre éstos fenómenos a nivel subatómico y las propiedades generales de los materiales ha permitido el desarrollo de materiales con nuevas propiedades o materiales de diseño.

Por otro lado, uno de los desarrollos más excitantes de la Física en los últimos años es la convergencia entre la Física de la Materia Condensada y las áreas de Información Cuántica y Computación Cuántica, lo que ha permitido un avance acelerado en ambos campos llevando de la mano a la teoría y al experimento. El principal motivo de esta convergencia es el estudio de los sistemas cuánticos de muchos cuerpos donde es indispensable entender el entrelazamiento cuántico que resulta ser el recurso principal para la teoría de información cuántica.

El Grupo de investigación se enfoca en las áreas de la física de la materia condensada, incluyendo varios grupos de estudio aplicados a mecánica estadística, mecánica cuántica, óptica, nanociencia, información cuántica, computación cuántica, etc.

3. Introducción

En este proyecto se aprenderá a programar, entrenar y estudiar las características internas de una Red Neuronal dedicada a la identificación de modelos físicos. Para este caso en particular estudiaremos la caída libre de partículas. Para la descripción de este movimiento usaremos la teoría de MRUV que se detalla en la sección 3.1. Los conocimientos matemáticos necesarios para la construcción de la red neuronal son cálculo y álgebra lineal. Algunos de estos conceptos se mencionan en la sección 3.2. La parte técnica y descriptiva de las redes neuronales se menciona en la sección 3.3, en esta, se explica su arquitectura, cómo funciona, y algunas funciones que ayudan a optimizar la capacidad de cómputo de una red neuronal. Una vez programada, se tomarán datos experimentales, dejando caer una partícula. Se tomarán videos de las trayectorias y posteriormente se analizarán los tiempos y se entrenará la red con dicha información. Este entrenamiento es posible gracias al aprendizaje automático. De esto se da una idea en la sección 3.4. Toda esta red será programada con TensorFlow, una tecnología desarrollada por Google para el desarrollo de redes neuronales; esto se menciona en 3.5.

3.1. Movimiento rectilíneo uniformemente variado

Para el caso de la caída libre de una partícula con velocidad inicial v_0 , durante un tiempo de caída t_f , la partícula habrá recorrido una distancia.

$$\Delta y = v_0 t_f + \frac{1}{2} a t_f^2,$$

La aceleración durante la caída libre es el valor de la gravedad. En este caso se dejará caer desde el reposo, lo que implicará que la velocidad inicial será cero. En este problema se toma el segundo término como positivo, ya que sólo estamos interesados en el cambio de posición de un punto A a otro B expresado como Δy , y el tiempo de caída. Como la aceleración está a favor del movimiento (la partícula acelera), la aceleración se toma como positiva.

3.2. Herramientas Matemáticas

3.2.1. Suma Ponderada

Una neurona artificial toma entradas representadas como $(x_1, x_2, \dots, x_n)$ y pesos representados como $(w_1, w_2, \dots, w_n)$. La suma ponderada se calcula multiplicando cada entrada por su peso correspondiente y sumando los resultados.

$$z = w_1 \cdot x_1 + w_2 \cdot x_2 + \dots + w_n \cdot x_n + b.$$

Donde b es el sesgo, en otras palabras es un valor constante.

La suma ponderada ajusta las entradas según su importancia relativa, determinada por los pesos. Estos pesos se adaptan durante el entrenamiento de la red neuronal [1].

3.2.2. Regresión Lineal

Dada una colección de datos, la línea de regresión es la recta que mejor se ajusta a los datos. Esto bajo el criterio de mínimos cuadrados. La ecuación de regresión lineal es:

$$\hat{y} = b_0 + b_1x.$$

Esto sirve para saber qué tan buenas son las predicciones hechas por el modelo [1].

3.2.3. Derivadas Parciales

Las derivadas parciales proporcionan información crucial sobre cómo una función cambia con respecto a cada una de sus variables independientes. Esto puede servir para medir la tasa de cambio de la función en una dirección específica y encontrar los puntos críticos de una función. Para la función de varias variables $z = f(x_1, x_2, \dots, x_n)$ respecto de una de sus variables se define como

$$\frac{\partial z}{\partial a} = \lim_{\Delta a \rightarrow 0} \frac{f(x_1, x_2, \dots, a + \Delta a, \dots, x_n) - f(x_1, x_2, \dots, x_n)}{\Delta a},$$

donde a es cualquiera de las variables de la función. Esto determina la razón de cambio de una función respecto de la variable deseada [2].

3.2.4. Regla de la Cadena

Si $z = f(u_1, u_2, \dots, u_n)$ y cada una de las variables u_i son funciones de $x_1, x_2, \dots, x_k$ entonces tenemos que [2]

$$\frac{\partial z}{\partial x_i} = \frac{\partial z}{\partial u_1} \frac{\partial u_1}{\partial x_i} + \frac{\partial z}{\partial u_2} \frac{\partial u_2}{\partial x_i} + \dots + \frac{\partial z}{\partial u_n} \frac{\partial u_n}{\partial x_i}.$$

Donde i puede tomar cualquier valor entero de 1 hasta k .

3.2.5. Divergencia

La divergencia en redes neuronales se utiliza para medir la disparidad entre dos distribuciones de probabilidad. En el contexto del aprendizaje automático, especialmente en técnicas de optimización, la divergencia se emplea para cuantificar qué tan lejos está una distribución aproximada de la verdadera distribución de los datos. Esto es se aplica en tareas como el entrenamiento de modelos generativos, donde se busca ajustar la distribución de salida del modelo lo más cercano posible a la distribución real de los datos, permitiendo una generación más precisa de nuevas muestras.

La divergencia de un campo arbitrario $\vec{F} = P\hat{i} + Q\hat{j} + R\hat{k}$ es la función escalar dada por

$$\text{div}\vec{F} = \nabla \cdot \vec{F} = \frac{\partial P}{\partial x} + \frac{\partial Q}{\partial y} + \frac{\partial R}{\partial z}.$$

En el contexto de Redes Neuronales, la divergencia se utiliza en la función de pérdida durante el entrenamiento de redes neuronales para guiar la optimización de los pesos [2].

3.3. Red Neuronal

3.3.1. Neurona

Una red neuronal es un conjunto interconectado de nodos llamados neuronas artificiales. Estas neuronas están organizadas en capas y se comunican entre sí mediante conexiones ponderadas. Cada neurona procesa información y la transmite a otras neuronas a través de estas conexiones.

Cada neurona toma la información de entrada, hace una suma ponderada, y transmite esta información a la siguiente neurona, o en su defecto como salida [3][4][5][6][7][8].

3.3.2. Capas

Hay diferentes tipos de capas neuronales.

- **Capa de entrada:** Recibe los valores de entrada de la red neuronal.
- **Capas ocultas:** Procesan la información de manera intermedia.
- **Capa de salida:** Dan los datos de salida de la red neuronal.

Cada neurona artificial se conecta a otras y tiene un peso y un umbral asociados. Si la salida de una neurona está por encima del valor de umbral especificado, se activa y envía datos a la siguiente capa de la red. De lo contrario, no se pasan datos a la siguiente capa [3][4][5][6][7][8].

3.3.3. Función de Activación

La función determina la salida de una neurona a partir de sus entradas. Estas funciones se aplican a la suma ponderada de las entradas y los pesos de una neurona. Su función principal es permitir la incorporación de modelado de datos no lineales en la red y facilitar el proceso de aprendizaje [9].

Algunas de las funciones más comunes para un valor de x , donde la variable x representa el valor de la suma ponderada de las entradas y los pesos en una neurona, son:

1. **Función Sigmoide:** Lleva los valores entre 0 y 1. Se utiliza especialmente para modelos en los que se necesita predecir probabilidades, como en la clasificación binaria. Su ecuación es:

$$f(x) = \frac{1}{1 + e^{-x}}$$




Figura 1: Gráfica de la función sigmoide. Fuente: Elaboración propia.

2. **Función Tangente Hiperbólica (tanh):** Su rango es de -1 a 1. Es similar a la función sigmoide, pero centrada en el origen. Se utiliza en redes neuronales para modelar relaciones no lineales. Su ecuación es:

$$f(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$




Figura 2: Gráfica de la función Tangente Hiperbólica. Fuente: Elaboración propia.

3. **Función Rectificadora Lineal (ReLU):** Es una función no lineal que devuelve 0 para valores negativos y el valor original para valores positivos. Su ecuación es:

$$f(x) = \max(0, x)$$




Figura 3: Gráfica de la función ReLU. Fuente: Elaboración propia.

3.3.4. Función de Coste

La función de coste en redes neuronales es crucial para determinar el error entre el valor estimado y el valor real durante el proceso de entrenamiento. Su objetivo principal es optimizar los parámetros de la red neuronal para que las predicciones se acerquen lo más posible a los valores reales. Algunas de las más utilizadas son: [3][4][5][6][7][8]

1. **Raíz Cuadrada Media (RMSE):** Calcula la raíz cuadrada media de los residuos, que son las diferencias entre los valores previstos (V_p) y los valores reales (V_r)

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (V_p - V_r)^2},$$

n es el número total de elementos en el conjunto de datos.

2. **Error Absoluto Medio (MAE):** Calcula la suma media de los valores absolutos de los errores. Es más fácil de interpretar que el RMSE, pero penaliza menos los valores grandes

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |x_i - x|,$$

donde $|x_i - x|$ representa los errores individuales y n es el número total de elementos en el conjunto de datos.

3. **Error Absoluto Medio Escalado (MASE):** Similar al MAE pero escalado. También es más fácil de interpretar y simétrico.

$$\text{MASE} = \frac{1}{n} \sum_{i=1}^n \left| \frac{q_i}{\text{MAE}} \right|,$$

donde n es el número de períodos de muestra de pronóstico, y q_i representa los errores absolutos individuales.

Además, existen optimizadores que trabajan con estas funciones de coste para ajustar los pesos de la red neuronal. Algunos ejemplos son:

- **Descenso Estocástico del Gradiente (SGD):** Aproximación estocástica del gradiente descendente que busca minimizar una función objetivo.
- **Adam:** Optimizador que adapta el ratio de aprendizaje en función de cómo están distribuidos los parámetros.

3.4. Aprendizaje Automático (Machine Learning)

3.4.1. Backpropagation

El backpropagation, también conocido como “propagación hacia atrás de errores”, es un algoritmo fundamental para el aprendizaje supervisado en redes neuronales artificiales. Su objetivo es ajustar los pesos de la red neuronal para minimizar el error entre las predicciones y los valores reales.

3.5. TensorFlow

TensorFlow es una plataforma de extremo a extremo enfocada en el aprendizaje automático. Es una biblioteca matemática simbólica que utiliza flujo de datos y programación diferenciable para realizar diversas tareas relacionadas con el entrenamiento e inferencia de redes neuronales profundas. TensorFlow es una plataforma de código abierto para el aprendizaje automático y el análisis de datos desarrollada por Google y liberada en 2015. Inicialmente, Google Brain, una división de investigación de inteligencia artificial de Google, desarrolló un sistema de aprendizaje automático llamado DistBelief. Para utilizar esta tecnología solo es necesaria la instalación de TensorFlow, se descarga e instala en un entorno de desarrollo, la descarga se puede hacer desde la página oficial [10].

4. Objetivos

4.1. General

- Estudiar la teoría, ejercicios, experiencias e historia del aprendizaje automático para entender la estructura interna de las redes neuronales aplicadas a la elaboración de modelos matemáticos que describan el comportamiento de los datos de montajes experimentales de caída libre..

4.2. Específicos

- Estudiar el desarrollo histórico y aplicaciones del aprendizaje automático para la física.
- Entender el funcionamiento de las redes neuronales de aprendizaje automático.
- Construir redes neuronales básicas y entrenarlas.
- Entrenar una red neuronal con ejemplos de M.R.U.V.

5. Justificación

Las redes neuronales y los sistemas de aprendizaje automático están cada día más presentes en la sociedad. Estas herramientas, a pesar de ser el foco de discusiones éticas y morales, son de gran ayuda en diversas áreas: artísticas, de productividad, financieras y, en especial, científicas. Las herramientas de aprendizaje automático permiten la resolución de tareas complejas en segundos. Además, se ha demostrado que son muy buenas al momento de buscar patrones y crear “modelos” matemáticos, ya que en esencia su construcción es matemática.

Tomando esto en cuenta, la idea es familiarizarse con la estructura, entrenamiento y aspectos técnicos de las redes neuronales. Para posteriormente estudiar el modelo que utiliza la red neuronal para reproducir los resultados experimentales. Una vez terminado, se tendrá una herramienta que puede ayudar en la didáctica y divulgación de la ciencia y tecnología.

Se espera que esto sienta las bases para el Ejercicio de Práctica Supervisada EPS que pretende seguir con este estudio y generalizar algunos aspectos para diferentes marcos teóricos.

Se espera que esto sienta las bases para el Ejercicio de Práctica Supervisada EPS que pretende seguir con este estudio y generalizar algunos aspectos para diferentes marcos teóricos.

La motivación personal es adquirir experiencia en áreas de interés personal, como lo son la física, tecnología y programación. Esto será una ayuda para desenvolverse en la industria o el mundo académico, según sea el caso. Esto sin desaprovechar la oportunidad de contribuir con la investigación nacional y el desarrollo tecnológico y científico de Guatemala.

6. Metodología

El proyecto se basa en aprender; la teoría de las redes neuronales de aprendizaje automático, la programación y creación de redes neuronales, a estudiar la estructura de la

red ya entrenada y probada. Para esto se consultarán distintos libros, artículos y contenido audiovisual. Con esto se comienza con el desarrollo del proyecto con la ayuda de la bibliografía y resolución de dudas del asesor para poder crear las redes neuronales que servirán para aprender lo antes mencionado. Después se hace un boceto del documento final para que el asesor brinde sus sugerencias y correcciones. Por último, se tendrá listo el informe final de prácticas.

7. Plan de trabajo

Este anteproyecto se presenta el 2 de mayo de 2024. Tras su aprobación se necesitarán 2 meses y dos semanas donde se trabajaran las tareas y se presentarán resultados semanalmente

	Mes 1				Mes 2				Mes 3	
	1	2	3	4	5	6	7	8	9	10
Tarea 1										
Tarea 2										
Tarea 3										
Tarea 4										
Tarea 5										
Tarea 6										

Las tareas están distribuidas así

Tarea 1: Elaboración del estado del arte de el problema.

Subtarea 1: Delimitar los tipos de movimiento.

Tarea 2: Familiarizarse con el lenguaje de programación.

Subtarea 1: Programar redes neuronales para entender el funcionamiento del lenguaje.

Subtarea 2: Estudiar la estructura de dichas redes.

Tarea 3: Estructura de la red neuronal.

Subtarea 1: Esquematizar la estructura para la red neuronal.

Subtarea 2: Tomar los datos para el entrenamiento y limpiar datos.

Tarea 4: Entrenamiento de la Red Neuronal.

Tarea 5: Estudio de la estructura de la red entrenada.

Tarea 6: Conclusiones y elaboración de informe final.

8. Bibliografía

Referencias comentadas

Todo lo pertinente a teoría física será tomado de Blatt [11]. La referencia estadística predeterminada será el libro de Mario [1]. La parte matemática es consultada en el libro de

cálculo, será el de Zill [2]. El canal de YouTube llamado DotCSV es una referencia audiovisual bastante completa en cuanto a redes neuronales se refiere [5, 6, 7, 8]. Para consultas técnicas rápidas y recomendaciones de la comunidad se usará la página de Wikipedia sobre "Función de activación" [9]. Las ayudas para entender el lenguaje serán tomadas de Amita y Martínez [12].

Como documentación complementaria, usaremos el libro de [13] para la parte del lenguaje.

Referencias

- [1] M. F. Triola, *Estadística*. Pearson Educación de México, S.A. de C.V., 2018.
- [2] D. G. Zill, *Cálculo con geometría analítica*. Grupo Editorial Iberoamérica, 1985.
- [3] J. Antonio, "Introducción a las redes neuronales: explicación completa en español," 08.
- [4] IBM, "¿qué son las redes neuronales? — ibm."
- [5] C. Santana, "¿qué es una red neuronal? parte 1 : La neurona — dotcsv," 03 2018.
- [6] C. Santana, "¿qué es una red neuronal? parte 2 : La red — dotcsv," 05 2018.
- [7] C. Santana, "¿qué es una red neuronal? parte 3 : Backpropagation — dotcsv," 10 2018.
- [8] C. Santana, "¿qué es una red neuronal? parte 3.5 : Las matemáticas de backpropagation — dotcsv," 10 2018.
- [9] W. Contributors, "Activation function," 11 2018.
- [10] www.tensorflow.com, "Por qué tensorflow," 2014.
- [11] F. J. Blatt, *Fundamentos de Física*. Prentice-Hall Hispanoamericana, S.A., 1991.
- [12] S. P. Amita Kapoor, Antonio Gulli, *Deep Learning with TensorFlow and Keras*. Packt Publishing Ltd., 2022.
- [13] J. Martínez', *TensorFlow 2.0 Computer Vision Cookbook*. Packt Publishing Ltd., 2021.