



UNIVERSIDAD DE SAN CARLOS DE GUATEMALA
ESCUELA DE CIENCIAS FÍSICAS Y MATEMÁTICAS

REDES NEURONALES DE APRENDIZAJE AUTOMÁTICO PARA LA INFERENCIA DE MODELOS FÍSICOS

Informe Final de Año de Prácticas elaborado por
Cesar Alejandro Barillas Segura
presentado ante el Departamento de Física

Supervisado por
Dr. Giovanni Ramírez García (ECFM-USAC)

Guatemala, 14 de agosto de 2026

Resumen

Se estudió si una red neuronal entrenada con datos experimentales de caída libre es capaz de inferir el modelo físico que los genera, es decir, si de la red entrenada puede recuperarse la aceleración de la gravedad g . Se grabaron 609 clips de video a 60 Hz de un cuerpo en caída libre, se digitalizaron sus trayectorias con *Tracker* y se obtuvieron 20 210 pares (t, y) útiles repartidos en 606 clips. Con esos datos se entrenaron tres arquitecturas en PyTorch: una red mínima $1 \rightarrow 2 \rightarrow 1$ que recibe únicamente el tiempo, una red $3 \rightarrow 4 \rightarrow 1$ que recibe tiempo, velocidad y aceleración verticales, y una red profunda con activaciones tanh ($1 \rightarrow 32 \rightarrow 32 \rightarrow 1$). El desempeño se midió con RMSE y MAE sobre la posición, y la inferencia del modelo físico se evaluó ajustando una parábola $y = c_0 + c_1 t + c_2 t^2$ a las predicciones y comparando $g = 2c_2$ con el valor obtenido de los datos experimentales.

Las tres redes alcanzan errores de posición muy parecidos (RMSE entre 0.507 y 0.514 m), pero ese valor apenas mejora al de un predictor trivial que devuelve siempre la posición media (RMSE = 0.619 m), lo que corresponde a un coeficiente de determinación $R^2 \approx 0.31$. Al estimar g *clip por clip* — que es el único nivel en el que la cantidad tiene sentido físico — los datos experimentales dan $g = -9.00 \pm 2.36 \text{ m/s}^2$ (mediana -9.38), consistente con el valor esperado, mientras que las redes devuelven 0.17, -3.25 y -3.60 m/s^2 respectivamente. Con el planteamiento inicial, por tanto, **las redes no inferen el modelo físico**: al agrupar 606 trayectorias con distinta altura inicial y distinto origen temporal bajo un único mapeo $y = f(t)$, el problema deja de ser identificable y la mejor solución posible es la media condicional de los datos, que es justamente lo que las redes aprenden. El fallo es de planteamiento, no de capacidad.

A partir de ese diagnóstico se rehízo el experimento refiriendo cada clip a su propio origen, con entradas (τ, v_0) y salida Δy , particionando por clip completo, con cinco semillas y tres líneas base clásicas de referencia. Con las *mismas* arquitecturas y los *mismos* datos, la red tanh profunda pasa de $R^2 = 0.33$ a $R^2 = 0.93$ y recupera $g = -9.46 \pm 0.33 \text{ m/s}^2$, a un 0.2 % del valor que el método clásico extrae de esos mismos datos (-9.48 m/s^2), además de superar en un 30 % al modelo analítico de MRUV con una única g ajustada. El supuesto del anteproyecto queda así verificado, y el informe documenta tanto el diagnóstico del fallo inicial como la reformulación que lo corrige.

Índice

Resumen	0
1. Descripción general de la Institución	3
2. Descripción del grupo de trabajo	3
3. Introducción	4
3.1. Movimiento rectilíneo uniformemente variado	4
3.2. Herramientas Matemáticas	5
3.2.1. Suma ponderada	5
3.2.2. Mínimos cuadrados y ajuste polinómico	5
3.2.3. Coeficiente de determinación	5
3.2.4. Derivadas parciales	6
3.2.5. Regla de la cadena	6
3.2.6. Normalización de los datos	6
3.3. Red Neuronal	6
3.3.1. Neurona	6
3.3.2. Capas	6
3.3.3. Función de activación	7
3.3.4. Función de coste	8
3.4. Aprendizaje automático	9
3.4.1. Backpropagation	9
3.4.2. Sobreajuste y validación	9
3.4.3. Identificabilidad del modelo	10
3.5. PyTorch	10
4. Objetivos	10
4.1. General	10
4.2. Específicos	10
5. Justificación	11
6. Metodología	11
6.1. Montaje experimental y toma de datos	11
6.2. Preprocesamiento	11
6.3. Arquitecturas evaluadas	12
6.4. Protocolo de evaluación	12
7. Resultados de la formulación inicial	13
7.1. Error de predicción	13
7.2. Recuperación de g : el ajuste agregado no es una prueba válida	14
7.3. Recuperación de g clip por clip	15
7.4. Diagnóstico: el problema no es identificable tal como se planteó	16
7.5. Efecto del número de épocas	17
7.6. Síntesis de la discusión	19

8. Verificación del supuesto: reformulación del problema	20
8.1. Rediseño del experimento	20
8.2. Recuperación del parámetro físico	21
8.3. Error de predicción y líneas base	23
8.4. El límite cambia de naturaleza	24
8.5. Síntesis	25
9. Limitaciones del estudio	25
9.1. Limitaciones de la formulación inicial, ya corregidas	25
9.2. Limitaciones que permanecen	26
10. Conclusiones	26
11. Trabajo futuro	27
12. Bibliografía	28

1. Descripción general de la Institución

La Universidad de San Carlos de Guatemala (USAC) es la institución de educación superior estatal, autónoma, con cultura democrática, con enfoque multi e intercultural, vinculada y comprometida con el desarrollo científico, social, humanista y ambiental, con una gestión actualizada, dinámica, efectiva y con recursos óptimamente utilizados para alcanzar sus fines y objetivos. Es la universidad más antigua de Guatemala, habiendo sido fundada el 31 de enero de 1676. El campus central se encuentra ubicado en el Departamento de Guatemala, Ciudad Universitaria 11 Avenida, Zona 12. Su lema es *Id y enseñad a todos*.

La Escuela de Ciencias Físicas y Matemáticas (ECFM) es una escuela no facultativa formada en el año 2009 en el evento CONVERGENCIA. Actualmente, la escuela cuenta con la carrera de Licenciatura en Física Aplicada y Licenciatura en Matemática Aplicada. La escuela cuenta también con un Instituto dedicado a la investigación de las ciencias físicas y matemáticas (IFIM) el cual ha presentado diversas investigaciones y publicado una variedad de artículos relacionados con la divulgación del conocimiento de las ciencias.

El IFIM es la unidad de la ECFM que promueve y realiza estudios avanzados en áreas científicas fundamentales y aplicadas de las ciencias físicas y matemáticas. Las áreas y líneas de investigación del Instituto son

1. Física de altas energías, cosmología y astrofísica: Física de partículas, Astrofísica de rayos gamma.
2. Ciencias no lineales y sistemas complejos: Materia condensada, Modelos numéricos del clima, Modelos matemáticos en ciencias de la salud.
3. Geofísica: Geodesia aplicada a la tectónica.
4. Física experimental: Detección de partículas e instrumentación electrónica, Redes de sensores.
5. Física de radiaciones: Control de calidad en radioterapia.

Además, el Instituto realiza actividades de difusión y divulgación, Seminarios científicos, Conferencias de divulgación científica y también Talleres y cursos cortos.

2. Descripción del grupo de trabajo

La Física de Materia Condensada es un área muy amplia e interesante. Mediante el estudio de las propiedades fundamentales de la materia se pueden observar fenómenos interesantes que permiten el desarrollo de nuevas tecnologías. En años recientes la relación entre éstos fenómenos a nivel subatómico y las propiedades generales de los materiales ha permitido el desarrollo de materiales con nuevas propiedades o materiales de diseño.

Por otro lado, uno de los desarrollos más excitantes de la Física en los últimos años es la convergencia entre la Física de la Materia Condensada y las áreas de Información Cuántica y Computación Cuántica, lo que ha permitido un avance acelerado en ambos campos llevando de la mano a la teoría y al experimento. El principal motivo de esta convergencia es el estudio de los sistemas cuánticos de muchos cuerpos donde es indispensable entender el entrelazamiento cuántico que resulta ser el recurso principal para la teoría de información cuántica.

El Grupo de investigación se enfoca en las áreas de la física de la materia condensada, incluyendo varios grupos de estudio aplicados a mecánica estadística, mecánica cuántica, óptica, nanociencia, información cuántica, computación cuántica, etc.

3. Introducción

En este proyecto se aprendió a programar, entrenar y estudiar las características internas de una red neuronal dedicada a la identificación de modelos físicos. El caso de estudio es la caída libre de un cuerpo, descrita por el movimiento rectilíneo uniformemente variado (MRUV) que se detalla en la sección 3.1. Los conocimientos matemáticos necesarios para construir y entrenar la red — suma ponderada, mínimos cuadrados, derivadas parciales y regla de la cadena — se resumen en la sección 3.2. La parte técnica y descriptiva de las redes neuronales, su arquitectura, sus funciones de activación y sus funciones de coste, se trata en la sección 3.3, y el mecanismo de aprendizaje en la sección 3.4. La implementación se realizó en PyTorch (sección 3.5).

La pregunta que organiza todo el trabajo no es si una red puede ajustar una curva — eso se sabe desde hace décadas — sino si de una red ya entrenada puede *extraerse* el modelo físico subyacente. Concretamente: si se entrena una red con trayectorias reales de caída libre y después se ajusta una parábola a sus predicciones, ¿aparece el valor correcto de g ? Ese es el criterio de éxito que se adoptó, y responderlo requiere tanto un montaje experimental que produzca datos suficientes (sección 6.1) como un protocolo de evaluación que sea válido (sección 6.4).

Conviene adelantar el desenlace, porque condiciona la lectura del resto del documento. El trabajo tiene dos partes. En la primera, con el planteamiento tal como se concibió en el anteproyecto, la respuesta es *negativa*: las redes no recuperan g . La razón no está en su capacidad sino en cómo se formuló el problema de aprendizaje, y la sección 7 presenta la evidencia junto con el diagnóstico (sección 7.4).

En la segunda parte se corrige ese planteamiento y se repite el experimento con las mismas arquitecturas y los mismos datos. La respuesta pasa a ser *afirmativa*: la red recupera la gravedad con una discrepancia del 0.2 % respecto de lo que el método clásico obtiene de esos mismos datos (sección 8). El supuesto del anteproyecto queda verificado, y el camino que llevó hasta ahí — un resultado negativo bien caracterizado que indica exactamente qué cambiar — es en sí mismo el aprendizaje central del proyecto.

3.1. Movimiento rectilíneo uniformemente variado

Un cuerpo que se mueve en línea recta con aceleración constante a describe la posición

$$y(t) = y_0 + v_0 t + \frac{1}{2} a t^2, \quad (1)$$

donde y_0 es la posición en $t = 0$ y v_0 la velocidad inicial. En caída libre, despreciando el arrastre del aire, la aceleración es la de la gravedad, $a = g$. Con el eje y orientado hacia arriba — que es la convención que usa *Tracker* y la que se mantiene en todo este informe — $g \approx -9.81 \text{ m/s}^2$, y tanto y como v_0 pueden ser negativos.

La ecuación (1) es el «marco teórico» cuya recuperación se busca. Tres observaciones sobre su estructura resultan decisivas más adelante:

1. g aparece únicamente en el coeficiente cuadrático. Si se ajusta $y = c_0 + c_1 t + c_2 t^2$ a una trayectoria, entonces $g = 2c_2$, y ese es el estimador que se usa en todo el trabajo.

2. Los tres coeficientes son independientes: y_0 y v_0 son propios de cada lanzamiento, mientras que g es común a todos. Una trayectoria queda determinada por la terna (y_0, v_0, g) , no por g sola.
3. Por lo tanto, t *no* determina y . Dos lanzamientos distintos con la misma t tienen posiciones distintas si difieren en y_0 o v_0 . Esta observación, aparentemente trivial, es la que explica los resultados de la sección 7.

3.2. Herramientas Matemáticas

3.2.1. Suma ponderada

Una neurona artificial toma entradas $(x_1, x_2, \dots, x_n)$ y pesos $(w_1, w_2, \dots, w_n)$. La suma ponderada se calcula multiplicando cada entrada por su peso correspondiente y sumando los resultados,

$$z = w_1x_1 + w_2x_2 + \dots + w_nx_n + b, \quad (2)$$

donde b es el sesgo, un valor constante. La suma ponderada pesa las entradas según su importancia relativa; esos pesos se adaptan durante el entrenamiento [1].

3.2.2. Mínimos cuadrados y ajuste polinómico

Dada una colección de datos, la recta de regresión es la que mejor se ajusta a ellos bajo el criterio de mínimos cuadrados, $\hat{y} = b_0 + b_1x$. El mismo criterio se generaliza a cualquier modelo lineal en los parámetros, y en particular a la parábola que interesa aquí. Dados N pares (t_i, y_i) se construye la matriz de diseño

$$\mathbf{T} = \begin{pmatrix} 1 & t_1 & t_1^2 \\ 1 & t_2 & t_2^2 \\ \vdots & \vdots & \vdots \\ 1 & t_N & t_N^2 \end{pmatrix}, \quad \mathbf{c} = (c_0, c_1, c_2)^\top, \quad (3)$$

y se busca el $\mathbf{c}$ que minimiza $\|\mathbf{T}\mathbf{c} - \mathbf{y}\|^2$, cuya solución es $\mathbf{c} = (\mathbf{T}^\top \mathbf{T})^{-1} \mathbf{T}^\top \mathbf{y}$. Comparando con (1) se identifica $c_0 = y_0$, $c_1 = v_0$ y $g = 2c_2$. Este ajuste es la herramienta central del trabajo: se aplica tanto a los datos experimentales como a las predicciones de cada red, y la comparación entre ambos valores de g es el criterio con el que se juzga si la red capturó la física [1].

Es importante notar una propiedad de este estimador que se explotará en la discusión: el ajuste solo tiene significado físico si todos los puntos (t_i, y_i) que entran en él pertenecen a *una misma trayectoria*. Si se mezclan trayectorias con distinto y_0 , distinto v_0 o distinto origen temporal, el c_2 resultante no es $g/2$ sino un número sin interpretación.

3.2.3. Coeficiente de determinación

Para juzgar si un modelo aporta información sobre la simple media de los datos se usa

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}, \quad (4)$$

donde $\bar{y}$ es la media muestral. $R^2 = 1$ corresponde a predicción perfecta y $R^2 = 0$ al desempeño de un modelo que devuelve siempre $\bar{y}$. Esta métrica resulta indispensable porque un RMSE «pequeño» solo significa algo al compararlo con la dispersión propia de los datos.

3.2.4. Derivadas parciales

Las derivadas parciales proporcionan información sobre cómo una función cambia respecto de cada una de sus variables independientes. Para $z = f(x_1, x_2, \dots, x_n)$ se define

$$\frac{\partial z}{\partial a} = \lim_{\Delta a \rightarrow 0} \frac{f(x_1, \dots, a + \Delta a, \dots, x_n) - f(x_1, \dots, x_n)}{\Delta a}, \quad (5)$$

donde a es cualquiera de las variables de la función [2]. En una red neuronal, las derivadas parciales de la función de coste respecto de cada peso son exactamente lo que el algoritmo de entrenamiento necesita para saber en qué dirección modificar ese peso.

3.2.5. Regla de la cadena

Si $z = f(u_1, u_2, \dots, u_n)$ y cada u_i es función de $x_1, x_2, \dots, x_k$, entonces [2]

$$\frac{\partial z}{\partial x_i} = \frac{\partial z}{\partial u_1} \frac{\partial u_1}{\partial x_i} + \frac{\partial z}{\partial u_2} \frac{\partial u_2}{\partial x_i} + \dots + \frac{\partial z}{\partial u_n} \frac{\partial u_n}{\partial x_i}, \quad (6)$$

donde i toma cualquier valor entero de 1 a k . Como una red neuronal es una composición de funciones — cada capa aplicada al resultado de la anterior — la ecuación (6) es literalmente el mecanismo que permite propagar el error desde la salida hasta la primera capa, y por eso reaparece en la sección 3.4.

3.2.6. Normalización de los datos

Antes de entrenar conviene llevar entradas y salidas a una escala común. La normalización z transforma cada variable según

$$\tilde{x} = \frac{x - \mu_x}{\sigma_x}, \quad (7)$$

con μ_x y σ_x la media y la desviación estándar muestrales. Esto evita que variables con rangos muy distintos — aquí, tiempos del orden de 10^{-1} s y posiciones del orden de 1 m — produzcan gradientes de magnitudes desbalanceadas. Las predicciones se desnormalizan con la transformación inversa antes de calcular cualquier métrica física, de modo que todos los errores reportados en este informe están en metros.

3.3. Red Neuronal

3.3.1. Neurona

Una red neuronal es un conjunto interconectado de nodos llamados neuronas artificiales. Estas neuronas están organizadas en capas y se comunican entre sí mediante conexiones ponderadas. Cada neurona toma la información de entrada, hace una suma ponderada, le aplica una función de activación y transmite el resultado a la siguiente neurona o, en su defecto, a la salida [3, 4, 5, 6, 7, 8].

3.3.2. Capas

Hay diferentes tipos de capas neuronales:

- **Capa de entrada:** recibe los valores de entrada de la red.

- **Capas ocultas:** procesan la información de manera intermedia.
- **Capa de salida:** entrega los datos de salida de la red.

Cada neurona artificial se conecta a otras y tiene un peso y un umbral asociados. Si la salida de una neurona está por encima del umbral, se activa y envía datos a la siguiente capa; de lo contrario no propaga información [3, 4].

El número de neuronas ocultas fija la *capacidad expresiva* de la red: una red con dos neuronas ocultas y activación ReLU solo puede representar funciones lineales a trozos con a lo sumo dos quiebres, mientras que dos capas de 32 neuronas tanh pueden aproximar cualquier función continua sobre un intervalo acotado con la precisión que se desee. Este contraste es deliberado en el diseño experimental de la sección 6.3.

3.3.3. Función de activación

La función de activación determina la salida de una neurona a partir de su suma ponderada. Su papel es introducir no linealidad: sin ella, una red de cualquier profundidad colapsa a una única transformación lineal [9]. Para un valor x igual a la suma ponderada de entradas y pesos, las funciones más comunes son:

1. **Función sigmoide:** lleva los valores al intervalo $(0, 1)$. Se usa sobre todo cuando se necesita predecir probabilidades, como en clasificación binaria. Su ecuación es

$$f(x) = \frac{1}{1 + e^{-x}}. \quad (8)$$




Figura 1: Gráfica de la función sigmoide. Fuente: elaboración propia.

2. **Tangente hiperbólica (tanh):** su rango es $(-1, 1)$. Es similar a la sigmoide pero centrada en el origen, lo que suele mejorar la convergencia. Su ecuación es

$$f(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}. \quad (9)$$




Figura 2: Gráfica de la función tangente hiperbólica. Fuente: elaboración propia.

3. **Rectificadora lineal (ReLU):** devuelve 0 para valores negativos y el valor original para valores positivos,

$$f(x) = \max(0, x). \quad (10)$$




Figura 3: Gráfica de la función ReLU. Fuente: elaboración propia.

La ReLU es barata de evaluar y su derivada no se satura para $x > 0$, pero tiene un modo de falla conocido: si durante el entrenamiento el argumento de una neurona se vuelve negativo para todos los datos, su gradiente es cero de forma permanente y la neurona deja de aprender. Este fenómeno, llamado *ReLU muerta*, es más probable cuanto menos neuronas tenga la capa, y se invocará en la sección 7.5 para explicar el comportamiento de la red $1 \rightarrow 2 \rightarrow 1$.

3.3.4. Función de coste

La función de coste mide el error entre el valor estimado y el valor real durante el entrenamiento. Su minimización es el objetivo de todo el proceso [3, 4]. Con $\hat{y}_i$ la predicción, y_i el valor real y n el número de muestras:

1. **Error cuadrático medio (MSE):** es la función que se minimiza durante el entrenamiento,

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2. \quad (11)$$

2. **Raíz del error cuadrático medio (RMSE):** es la raíz del anterior,

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2}, \quad (12)$$

con la ventaja de estar en las mismas unidades que la variable predicha — metros, en este trabajo. Penaliza fuertemente los errores grandes.

3. **Error absoluto medio (MAE):** promedia los valores absolutos de los errores,

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |\hat{y}_i - y_i|. \quad (13)$$

Es más fácil de interpretar que el RMSE y menos sensible a valores atípicos.

Un punto que conviene subrayar, porque se vuelve central en el análisis: MSE, RMSE y MAE son medidas *relativas*. Un RMSE de 0.5 m es excelente si los datos varían en decenas de metros y es pésimo si varían en centímetros. Por eso todo RMSE reportado aquí se acompaña del RMSE del predictor constante $\hat{y} = \bar{y}$, cuyo valor es exactamente la desviación estándar de los datos, y del R^2 de la ecuación (4).

Además, existen optimizadores que usan estas funciones de coste para ajustar los pesos:

- **Descenso estocástico del gradiente (SGD):** actualiza los pesos en la dirección opuesta al gradiente estimado sobre un subconjunto (lote) de los datos, $w \leftarrow w - \eta \partial C / \partial w$, con η la tasa de aprendizaje.
- **Adam:** adapta la tasa de aprendizaje de cada parámetro usando estimaciones del primer y segundo momento del gradiente. Es el optimizador empleado en todos los entrenamientos de este trabajo, con $\eta = 10^{-3}$.

3.4. Aprendizaje automático

3.4.1. Backpropagation

El *backpropagation*, o propagación hacia atrás de errores, es el algoritmo fundamental del aprendizaje supervisado en redes neuronales. Su objetivo es ajustar los pesos para minimizar el error entre las predicciones y los valores reales, y consiste en aplicar la regla de la cadena (6) desde la salida hacia la entrada: se calcula el error en la capa de salida, se propaga hacia atrás capa por capa multiplicando por las derivadas locales, y con las derivadas parciales resultantes $\partial C / \partial w$ el optimizador actualiza cada peso. El ciclo completo sobre todo el conjunto de entrenamiento es una *época*.

3.4.2. Sobreajuste y validación

Entrenar durante muchas épocas puede llevar a que la red memorice particularidades del conjunto de entrenamiento en lugar de aprender la regularidad subyacente. Para detectarlo se separan los datos en un conjunto de entrenamiento y uno de validación, y se vigila que el error de validación no empiece a crecer mientras el de entrenamiento sigue bajando.

La forma en que se hace esa separación importa tanto como el hecho de hacerla. Si los datos provienen de experimentos repetidos, repartir los puntos individuales al azar hace que puntos de una misma trayectoria caigan a ambos lados de la partición; entonces el conjunto de validación no mide capacidad de generalización a un experimento nuevo, sino solo de interpolación dentro de experimentos ya vistos. La alternativa correcta es particionar por experimento completo (validación *leave-one-clip-out*). Este trabajo empleó la partición aleatoria por puntos, y en la sección 9 se discuten sus consecuencias.

3.4.3. Identificabilidad del modelo

Existe una condición previa a cualquier consideración de arquitectura o de entrenamiento, y es que el problema planteado tenga solución. Si se busca una función f tal que $y \approx f(x)$ y en los datos existen pares (x, y_a) y (x, y_b) con $y_a \neq y_b$, ninguna función puede reproducir ambos: el problema es *no identificable* a partir de x .

En ese caso la teoría de la regresión da una respuesta precisa. El minimizador del error cuadrático esperado es la media condicional,

$$f^*(x) = \mathbb{E}[y \mid x], \quad (14)$$

y el error residual mínimo alcanzable es la varianza condicional $\mathbb{E}[\text{Var}(y \mid x)]$, que no puede reducirse por más capacidad o más épocas que se le den al modelo. Una red suficientemente expresiva entrenada con MSE converge a (14), no a la ley física que generó los datos. Distinguir un fallo de este tipo de un fallo de capacidad o de entrenamiento es esencial para interpretar correctamente los resultados de la sección 7.

3.5. PyTorch

El anteproyecto contemplaba usar TensorFlow [10], la plataforma de aprendizaje automático desarrollada por Google y liberada en 2015. Durante la implementación se migró a **PyTorch**, biblioteca de código abierto mantenida por Meta AI, por dos razones prácticas: su modo de ejecución inmediata (*eager*) permite inspeccionar tensores y gradientes con un depurador convencional, lo que resultó decisivo para un proyecto cuyo objetivo es *estudiar* el interior de la red y no solo entrenarla; y su API de módulos (`torch.nn`) expresa arquitecturas pequeñas y no estándar con menos código intermedio. Ambas bibliotecas implementan diferenciación automática sobre grafos de cómputo y son equivalentes para los fines de este trabajo. Los conceptos descritos en las secciones anteriores — capas lineales, activaciones, función de coste, optimizador Adam — se traducen directamente a las clases `nn.Linear`, `nn.ReLU/nn.Tanh`, `nn.MSELoss` y `torch.optim.Adam`.

El entorno de trabajo se gestionó con `conda` (entorno `practicass`) y todos los scripts, datos y salidas quedaron versionados en el repositorio del proyecto.

4. Objetivos

4.1. General

- Estudiar la teoría, ejercicios, experiencias e historia del aprendizaje automático para entender la estructura interna de las redes neuronales aplicadas a la elaboración de modelos matemáticos que describan el comportamiento de los datos de montajes experimentales de caída libre.

4.2. Específicos

- Estudiar el desarrollo histórico y aplicaciones del aprendizaje automático para la física.
- Entender el funcionamiento de las redes neuronales de aprendizaje automático.
- Construir redes neuronales básicas y entrenarlas.
- Entrenar una red neuronal con ejemplos de MRUV.

5. Justificación

Las redes neuronales y los sistemas de aprendizaje automático están cada día más presentes en la sociedad. Estas herramientas, a pesar de ser el foco de discusiones éticas y morales, son de gran ayuda en diversas áreas: artísticas, de productividad, financieras y, en especial, científicas. Las herramientas de aprendizaje automático permiten la resolución de tareas complejas en segundos. Además, se ha demostrado que son muy buenas al momento de buscar patrones y crear «modelos» matemáticos, ya que en esencia su construcción es matemática.

Tomando esto en cuenta, la idea es familiarizarse con la estructura, entrenamiento y aspectos técnicos de las redes neuronales, para posteriormente estudiar el modelo que utiliza la red para reproducir los resultados experimentales. Una vez terminado, se tendrá una herramienta que puede ayudar en la didáctica y divulgación de la ciencia y la tecnología.

Se espera que esto sienta las bases para el Ejercicio de Práctica Supervisada (EPS), que pretende seguir con este estudio y generalizar algunos aspectos para diferentes marcos teóricos.

La motivación personal es adquirir experiencia en áreas de interés personal, como lo son la física, la tecnología y la programación. Esto será una ayuda para desenvolverme en la industria o en el mundo académico, según sea el caso, sin desaprovechar la oportunidad de contribuir con la investigación nacional y el desarrollo tecnológico y científico de Guatemala.

6. Metodología

El proyecto se desarrolló en cuatro etapas: estudio bibliográfico de redes neuronales, montaje y digitalización del experimento de caída libre, implementación y entrenamiento de las arquitecturas, y análisis de las redes entrenadas. Las tres últimas se detallan a continuación.

6.1. Montaje experimental y toma de datos

Se grabaron **609 clips** de video de un cuerpo dejándose caer desde el reposo, a una frecuencia de 60 Hz ($\Delta t = 1/60$ s ≈ 16.7 ms). Cada video se segmentó en clips individuales y se digitalizó con *Tracker*, obteniendo para cada fotograma la tupla $(t, x, y, v_x, v_y, a_x, a_y)$; las velocidades y aceleraciones son derivadas numéricas que el propio programa calcula por diferencias finitas sobre las posiciones. La escala espacial se fijó con una referencia de longitud conocida en el campo de visión, de modo que las posiciones están en metros y el eje y apunta hacia arriba.

De los 609 clips, **606 contienen datos utilizables**, con un total de 20 210 **pares** (t, y) . Cada clip tiene en promedio 33 puntos y una duración media de 0.54 s. Los archivos resultantes se almacenaron en formato de texto en `Toma_de_datos/datos/`.

6.2. Preprocesamiento

Todos los clips se concatenaron en un único conjunto de entrenamiento. Se descartaron las filas con valores faltantes — característicamente las primeras filas de cada archivo, donde *Tracker* aún no puede calcular derivadas — y se aplicó la normalización z de la ecuación (7) a entradas y salidas, con estadísticos calculados sobre el conjunto completo.

La partición entrenamiento/validación fue 80 %/20 % *por punto individual*, con lotes de 512 muestras.

Este paso, que parece rutinario, contiene la decisión de diseño más consecuente de todo el trabajo, y la sección 7.4 la examina en detalle.

6.3. Arquitecturas evaluadas

Se compararon tres configuraciones, elegidas para separar el efecto de la *información física suministrada* del efecto de la *capacidad expresiva*:

- **Red simple** $1 \rightarrow 2 \rightarrow 1$. Recibe únicamente el tiempo. Una capa oculta de dos neuronas con activación ReLU. Es la prueba más exigente: debe reconstruir la relación cuadrática sin ninguna ayuda.
- **Red** $3 \rightarrow 4 \rightarrow 1$. Recibe tiempo, velocidad vertical v_y y aceleración vertical a_y . Una capa oculta de cuatro neuronas con activación ReLU. Se le suministran explícitamente las variables dinámicas del problema.
- **Red tanh profunda**. Recibe únicamente el tiempo. Dos capas ocultas de 32 neuronas con activación tanh ($1 \rightarrow 32 \rightarrow 32 \rightarrow 1$). Tiene capacidad expresiva muy superior a las anteriores, pero la misma información de entrada que la red simple.

Las tres se entrenaron con optimizador Adam, tasa de aprendizaje 10^{-3} y función de coste MSE sobre los datos normalizados.

6.4. Protocolo de evaluación

El desempeño se evaluó en dos niveles.

Nivel 1: error de predicción. Se calcularon RMSE y MAE sobre la posición desnormalizada, en metros, y el coeficiente de determinación R^2 de la ecuación (4) para situar esos errores frente a la dispersión propia de los datos.

Nivel 2: recuperación del parámetro físico. Se ajustó la parábola $y = c_0 + c_1 t + c_2 t^2$ de la sección 3.2.2 a las predicciones de la red y se tomó $g_{\text{pred}} = 2c_2$. El mismo ajuste aplicado a los datos experimentales da g_{ref} , y la comparación entre ambos es el criterio de éxito.

La hipótesis de trabajo era que si una red «entiende» el marco teórico de la caída libre debe (i) aproximar bien la posición, (ii) estimar correctamente g al ajustarle una parábola a sus predicciones, y (iii) mantener estable esa estimación al variar el número de épocas.

Ahora bien, el nivel 2 admite dos implementaciones que *no* son equivalentes:

Ajuste agregado. Un único ajuste sobre los 20 210 puntos de los 606 clips a la vez.

Ajuste por clip. Un ajuste independiente para cada clip, seguido del análisis estadístico de los 606 valores de g resultantes.

La primera versión fue la que se empleó inicialmente y la que produjo las conclusiones optimistas que motivaron una revisión; la sección 7.2 muestra por qué es inválida. Solo la segunda respeta la condición señalada en la sección 3.2.2: que todos los puntos de un ajuste

pertenezcan a una misma trayectoria. Los resultados se reportan con ambas para dejar el contraste explícito.

Adicionalmente se realizó un estudio del efecto del número de épocas, entrenando cada arquitectura con 10, 20, 50, 100, 200, 400 y 700 épocas y registrando RMSE, MAE y tiempo de cómputo.

7. Resultados de la formulación inicial

7.1. Error de predicción

La tabla 1 recoge las métricas globales de las tres redes, junto con el predictor constante $\hat{y} = \bar{y}$ como referencia.

Modelo	RMSE [m]	MAE [m]	r	R^2
Red $3 \rightarrow 4 \rightarrow 1$	0.5068	0.4265	0.574	0.329
Red tanh profunda	0.5123	0.4323	0.561	0.314
Red simple $1 \rightarrow 2 \rightarrow 1$	0.5140	0.4344	0.557	0.310
Predictor constante $\bar{y}$	0.6186	—	—	0.000

Cuadro 1: Métricas globales sobre las 20 210 muestras. r es el coeficiente de correlación de Pearson entre predicción y valor experimental. La última fila corresponde a un modelo que devuelve siempre la posición media, cuyo RMSE es por construcción la desviación estándar de los datos.

El orden de desempeño es el esperado: la red que recibe información dinámica explícita ($3 \rightarrow 4 \rightarrow 1$) queda primera, la red tanh segunda y la red mínima tercera. Sin embargo, las diferencias son minúsculas — 1.4 % entre la mejor y la peor — y quedan por debajo de la variabilidad que introduce la inicialización aleatoria de los pesos, como se aprecia en la tabla 4 más adelante. Con una sola semilla por configuración no es posible afirmar que ese orden sea significativo.

Más revelador es el contraste con la última fila. El predictor constante, que ignora por completo la entrada, alcanza $\text{RMSE} = 0.6186$ m. La mejor red lo mejora hasta 0.5068 m, es decir, un 18 %. En términos de varianza explicada, $R^2 \approx 0.33$: las redes capturan alrededor de un tercio de la estructura de los datos y dejan dos tercios sin explicar. Para un fenómeno determinista como la caída libre, medido con instrumentación adecuada, un R^2 de 0.33 es un indicador de que algo está mal planteado, no de que el ajuste sea razonablemente bueno.

La figura 4 lo muestra directamente: si las redes reprodujeran las trayectorias, los puntos se alinearían sobre la diagonal. En cambio forman una nube ancha, y las predicciones ocupan un rango mucho más estrecho que los valores experimentales — señal característica de un modelo que está devolviendo un promedio.




Figura 4: Posición predicha frente a posición experimental para las tres redes. La línea discontinua es la identidad. El estrechamiento vertical de la nube respecto de su extensión horizontal indica que las redes comprimen la variabilidad de los datos hacia un valor medio.

7.2. Recuperación de g : el ajuste agregado no es una prueba válida

Aplicando el ajuste cuadrático sobre el conjunto agregado, tal como se hizo en la primera versión del análisis, se obtienen los valores de la tabla 2.

Modelo	g_{pred}	g_{ref}	Diferencia
Red $3 \rightarrow 4 \rightarrow 1$	-0.3564	-0.3500	-0.0064
Red tanh profunda	-0.3570	-0.3500	-0.0070
Red simple $1 \rightarrow 2 \rightarrow 1$	-0.3438	-0.3500	+0.0062

Cuadro 2: Estimación de g (en m/s^2) mediante un único ajuste cuadrático sobre los 20 210 puntos agregados. Las diferencias con el valor de referencia son inferiores al 2 %, pero *ese valor de referencia no es la aceleración de la gravedad*.

Leída sin más contexto, esta tabla sugiere un acuerdo excelente: las tres redes reproducen el coeficiente de referencia con menos del 2 % de discrepancia. La conclusión es, sin embargo, incorrecta, y la razón está a la vista en el propio valor de referencia: $g_{\text{ref}} = -0.35 \text{ m/s}^2$ difiere del valor esperado -9.81 m/s^2 en un factor de 28.

El origen del problema se ilustra en la figura 5. Cada clip tiene su propio origen temporal, heredado del video del que se extrajo, de modo que los 20 210 puntos se reparten sobre un intervalo de 0 a 10.4 s aunque cada trayectoria individual dure apenas 0.54 s en promedio. Además, cada clip parte de una altura inicial distinta. La parábola que mejor ajusta esa nube heterogénea es una curva que no pasa cerca de ningún dato real — alcanza su vértice en $t \approx 5.2 \text{ s}$, donde no hay observaciones — y su coeficiente c_2 no tiene nada que ver con la gravedad. Es, simplemente, el número que minimiza el error sobre una mezcla de trayectorias incompatibles entre sí.




Figura 5: (a) Los 20 210 puntos experimentales superpuestos y la parábola ajustada al conjunto agregado. La curva ajustada se aleja de los datos, que se concentran en $t < 1$ s, y su coeficiente cuadrático corresponde a $g = +0.350 \text{ m/s}^2$, sin significado físico. (b) Seis clips individuales; cada uno tiene su propia altura inicial y un ajuste parabólico propio con g del orden de -9 m/s^2 .

En consecuencia, el acuerdo de la tabla 2 no mide comprensión física. Mide que las redes y el ajuste agregado están cometiendo el mismo error sobre los mismos datos mal combinados, lo cual era de esperar y no aporta información. El criterio de validación debe aplicarse clip por clip.

7.3. Recuperación de g clip por clip

Al ajustar una parábola independiente a cada uno de los 606 clips el panorama cambia por completo. La tabla 3 recoge la estadística de esas 606 estimaciones para los datos experimentales y para las predicciones de cada red.

Fuente	Media	Mediana	Desv. est.
Datos experimentales	-9.00	-9.38	2.36
Red 3 $\rightarrow$ 4 $\rightarrow$ 1	-3.25	-2.99	2.41
Red tanh profunda	-3.60	-2.89	2.80
Red simple 1 $\rightarrow$ 2 $\rightarrow$ 1	+0.17	-0.00	0.59

Cuadro 3: Estadística de las 606 estimaciones de g (m/s^2) obtenidas ajustando una parábola por clip. El valor de referencia físico es -9.81 m/s^2 .

Los datos experimentales superan la prueba: la mediana de -9.38 m/s^2 está a un 4 % del valor esperado, lo que confirma que el montaje experimental y la digitalización con *Tracker* son adecuados y que la información física *está presente en los datos*. La dispersión de 2.36 m/s^2 es apreciable y se atribuye a la corta duración de cada clip — media 0.54 s, unos 33 puntos — combinada con la resolución espacial del seguimiento; en la figura 5(b) se aprecia el escalonado característico de la cuantización a nivel de píxel, que afecta más al coeficiente cuadrático que a los de orden inferior.

Las redes, en cambio, no la superan. Las dos mejores recuperan alrededor de un tercio del valor correcto, y la red simple $1 \rightarrow 2 \rightarrow 1$ devuelve esencialmente cero: sus predicciones dentro de cada clip son casi una recta, de modo que el coeficiente cuadrático se anula. La figura 6 muestra las distribuciones completas y hace evidente que no se trata de un sesgo pequeño sino de dos poblaciones separadas.




Figura 6: Distribución de las 606 estimaciones de g por clip. En azul, las obtenidas de los datos experimentales, centradas cerca del valor esperado (línea discontinua). En rojo, las obtenidas de las predicciones de cada red. La red simple concentra toda su masa en $g \approx 0$; las otras dos alcanzan aproximadamente un tercio del valor correcto.

Corresponde por tanto corregir la conclusión que se había extraído del ajuste agregado: **ninguna de las tres redes infiere el modelo físico de la caída libre**. El acuerdo aparente de la tabla 2 era un artefacto del protocolo de evaluación.

7.4. Diagnóstico: el problema no es identificable tal como se planteó

La causa del fracaso no está en las arquitecturas ni en el entrenamiento, sino en la formulación del problema de aprendizaje, y se sigue de la tercera observación de la sección 3.1.

Al concatenar los 606 clips y pedir a la red que aprenda un mapeo $y = f(t)$, se está exigiendo que un único valor de entrada produzca un único valor de salida. Pero en el conjunto de entrenamiento hay, para cada instante t del rango útil, decenas de puntos procedentes de clips distintos con alturas iniciales distintas: el mismo t aparece asociado a valores de y que difieren en más de un metro. Ninguna función puede satisfacer simultáneamente todas esas restricciones. El problema es no identificable en el sentido de la sección 3.4.3.

Lo que sigue es entonces predecible. Al minimizar el error cuadrático, la solución óptima es la media condicional $f^*(t) = \mathbb{E}[y | t]$ de la ecuación (14): para cada instante, el promedio de las posiciones de todos los clips en ese instante. Como los clips no están sincronizados ni comparten altura inicial, ese promedio es una curva suave y casi lineal que no corresponde a ninguna trayectoria real y cuyo coeficiente cuadrático es próximo a cero. Es exactamente lo que devuelven las redes.

La figura 7 confirma el diagnóstico de la manera más directa. En los cuatro clips mostrados, las tres redes producen prácticamente la *misma* curva, independientemente del clip: no pueden hacer otra cosa, porque su única entrada es t y todos los clips comienzan en $t = 0$. Cuando la altura inicial del clip coincide aproximadamente con la media del conjunto (paneles tercero y cuarto) la predicción parece razonable; cuando no coincide (paneles primero y segundo) el desfase es de casi un metro. Esa es la fuente del RMSE de 0.51 m y

del R^2 de 0.31.




Figura 7: Cuatro clips experimentales (puntos negros) con las predicciones de las tres redes superpuestas. Las predicciones son casi idénticas entre clips, porque la entrada t no distingue un clip de otro. El desajuste vertical en los dos primeros paneles corresponde a clips cuya altura inicial se aparta de la media del conjunto.

Esto explica también por qué la red $3 \rightarrow 4 \rightarrow 1$ es la única que se acerca algo al valor correcto. Sus entradas v_y y a_y sí distinguen un clip de otro: codifican el estado dinámico instantáneo y, en principio, permiten reconstruir la trayectoria. La red aprovecha esa información y pasa de $g \approx 0$ a $g \approx -3 \text{ m/s}^2$. No llega más lejos por dos motivos: v_y y a_y son derivadas numéricas obtenidas por diferencias finitas y por tanto mucho más ruidosas que las posiciones — particularmente a_y , que es una segunda derivada —, y una capa oculta de cuatro unidades ReLU no tiene capacidad para representar los productos y composiciones que exigiría la reconstrucción exacta. La mejora observada es, en cualquier caso, consistente con el diagnóstico: suministrar información que identifique el clip es lo que hace avanzar el resultado.

Por el mismo argumento se entiende que la red tanh profunda, con 1153 parámetros frente a los 7 de la red simple, no supere de forma clara a la red $3 \rightarrow 4 \rightarrow 1$, que tiene 21. Cuando el límite es de identificabilidad y no de capacidad, añadir parámetros no ayuda: la red tanh simplemente aprende la media condicional con mayor fidelidad, lo que la acerca a un R^2 ligeramente distinto pero no le permite recuperar g .

7.5. Efecto del número de épocas

La tabla 4 recoge el estudio del número de épocas y la figura 8 lo resume gráficamente.

Modelo	Épocas	Tiempo [s]	RMSE [m]	MAE [m]
Red simple $1 \rightarrow 2 \rightarrow 1$	10	3.15	0.6749	0.5760
	20	2.60	0.6061	0.5114
	50	8.64	0.5236	0.4479
	100	14.81	0.6186	0.5223
	200	29.12	0.6029	0.5060
	400	59.14	0.5126	0.4332
	700	101.86	0.6029	0.5061
Red $3 \rightarrow 4 \rightarrow 1$	10	1.46	0.5874	0.4932
	20	2.90	0.5571	0.4724
	50	7.50	0.5117	0.4319
	100	14.57	0.5096	0.4304
	200	32.08	0.5073	0.4268
	400	59.87	0.5106	0.4307
	700	100.69	0.5064	0.4265
Red tanh profunda	10	1.76	0.5164	0.4360
	20	3.13	0.5134	0.4347
	50	8.37	0.5130	0.4336
	100	16.44	0.5129	0.4336
	200	32.63	0.5129	0.4340
	400	67.43	0.5122	0.4324
	700	109.56	0.5121	0.4322

Cuadro 4: Impacto del número de épocas en RMSE, MAE y tiempo de entrenamiento. Cada fila es un entrenamiento independiente con inicialización aleatoria propia.




Figura 8: Tiempo de entrenamiento frente a épocas (izquierda) y RMSE frente a épocas (derecha) para las tres redes evaluadas.




Figura 9: Gráficos individuales de RMSE y MAE frente al número de épocas para cada red. Se observa la oscilación de la red simple (izquierda), la convergencia progresiva de la red $3 \rightarrow 4 \rightarrow 1$ (centro) y la convergencia temprana de la red tanh (derecha).

Tres observaciones.

La red tanh converge de inmediato. A partir de 50 épocas su RMSE es prácticamente invariante (0.5120 frente a 0.5121 en 700 épocas, una diferencia del 0.2 % a costa de trece veces más cómputo). Esto es coherente con la interpretación de la sección 7.4: la media condicional es una función suave y fácil de aproximar, y una vez alcanzada no hay nada más que aprender. El estancamiento no es un límite de la red, es el suelo de error impuesto por la varianza condicional de los datos.

La red $3 \rightarrow 4 \rightarrow 1$ mejora de forma gradual y modesta. Baja de 0.5874 a 0.5064 entre 10 y 700 épocas. Su información adicional le permite reducir algo el error, pero la curva se aplanar rápidamente y la mejora entre 200 y 700 épocas es inferior al 0.2 %.

La red simple oscila. Su RMSE alterna entre 0.51 y 0.67 sin tendencia monótona: mejora hasta 50 épocas, empeora a 100, mejora a 400 y vuelve a empeorar a 700. En la primera versión del análisis esta oscilación se interpretó como sobreajuste posterior al «descubrimiento» de la física. Esa lectura no se sostiene, por dos razones. La primera es que el sobreajuste produce un patrón distinto — error de entrenamiento que sigue bajando mientras el de validación sube de forma sostenida — y no una alternancia no monótona. La segunda es que con siete parámetros y 20 210 muestras el sobreajuste es prácticamente imposible.

La explicación es más simple. Cada fila de la tabla es un entrenamiento independiente con su propia inicialización aleatoria, y con solo dos neuronas ocultas ReLU el resultado depende críticamente de esa inicialización: basta con que una de las dos unidades quede en la región de gradiente nulo — el fenómeno de ReLU muerta descrito en la sección 3.3 — para que la red se reduzca de hecho a una sola neurona. Los valores de $\text{RMSE} \approx 0.60$ y $\text{RMSE} \approx 0.51$ corresponden verosímilmente a esos dos regímenes. La oscilación es, por tanto, dispersión entre semillas y no una dinámica de aprendizaje; comprobarlo requeriría repetir cada configuración con varias semillas, lo que se recomienda en la sección 11.

7.6. Síntesis de la discusión

Reuniendo los tres niveles de evidencia:

- Las tres redes alcanzan un RMSE que mejora solo un 18 % al del predictor constante, con $R^2 \approx 0.31$ (tabla 1).
- Los datos experimentales contienen la física buscada: ajustados clip por clip dan g con mediana -9.38 m/s^2 (tabla 3).
- Las predicciones de las redes, sometidas al mismo ajuste, dan entre 0 y -3.6 m/s^2 (tabla 3, figura 6).
- Las predicciones son casi idénticas para clips distintos (figura 7), como corresponde a un modelo que aproxima la media condicional.

Todo apunta en la misma dirección: las redes aprendieron el promedio de un conjunto de trayectorias incompatibles entre sí, no la ley que las genera. El fallo es de planteamiento, no de capacidad, y esa distinción es precisamente lo que hace que el resultado sea utilizable: indica qué hay que cambiar.

La sección siguiente aplica ese cambio y comprueba si basta.

8. Verificación del supuesto: reformulación del problema

El diagnóstico de la sección 7.4 tiene una consecuencia práctica inmediata: si el fallo es de planteamiento y no de las redes, entonces corregir el planteamiento debería bastar para que el supuesto del anteproyecto pueda verificarse. Esta sección lo pone a prueba. Todo el código correspondiente está en la carpeta `Proyectov2/` del repositorio del proyecto.

8.1. Rediseño del experimento

La corrección central es referir cada clip a su propio origen. Con $\tau = t - t_0$ y $\Delta y = y - y_0$ medidos *dentro* de cada clip, la ecuación (1) se convierte en

$$\Delta y = v_0 \tau + \frac{1}{2} g \tau^2, \quad (15)$$

donde y_0 ha desaparecido y g es el único parámetro compartido por todas las trayectorias. La altura inicial, que era la causa de la ambigüedad, deja de intervenir.

Queda v_0 . La velocidad inicial no es la misma en todos los clips —media -0.21 m/s , desviación estándar 0.25 m/s — porque no todos empiezan en el instante exacto de la soltada. Sin v_0 el problema sigue siendo parcialmente ambiguo, así que se incluye como segunda entrada. Se estima con un ajuste lineal a los *tres primeros puntos* de cada clip: *Tracker* no proporciona velocidad en el primer fotograma, y usar solo el arranque evita que la estimación absorba la curvatura, que es justamente lo que se quiere medir después.

Para no dar por supuesto el efecto de cada cambio, se evalúan tres formulaciones:

v1: $t \rightarrow y$, clips concatenados. Reproduce el planteamiento original y sirve de control.

tau: $\tau \rightarrow \Delta y$. Solo el cambio de origen.

tau_v0: $(\tau, v_0) \rightarrow \Delta y$. Formulación identificable completa.

El resto del protocolo se corrigió según las limitaciones detectadas en la sección 9. La tabla 5 resume las diferencias.

	Versión inicial	Versión corregida
Formulación	$t \rightarrow y$, clips concatenados	$(\tau, v_0) \rightarrow \Delta y$
Partición	80 %/20 % por <i>punto</i>	por <i>clip</i> completo, 70/15/15
Normalización	sobre todo el conjunto	solo con clips de entrenamiento
Semillas	1	5, con media y desviación
Parada	número fijo de épocas	temprana, sobre clips no vistos
Líneas base	ninguna	tres (véase sección 8.3)
Estimación de g	un ajuste sobre el agregado	un ajuste <i>por clip</i>
Calidad de datos	sin filtro	descarta residuo > 8 cm

Cuadro 5: Diferencias de protocolo entre la formulación inicial y la corregida. Las arquitecturas de red son deliberadamente las mismas, de modo que cualquier cambio en el resultado provenga del planteamiento del problema y no de haber usado redes distintas.

El filtro de calidad descarta los clips cuyo ajuste parabólico deja un residuo superior a 8 cm, que corresponden a fallos de seguimiento de *Tracker* y no a trayectorias físicamente distintas. Elimina 25 de los 606 clips (4 %) y deja 581 clips con 18 992 muestras. Sobre ese conjunto la referencia experimental es

$$g_{\text{exp}} = -9.43 \text{ m/s}^2 \quad (\text{mediana del ajuste por clip}), \quad (16)$$

a un 3.9 % del valor físico -9.81 m/s^2 . Esa diferencia es un sesgo del montaje experimental, y conviene tenerla presente: **una red no puede recuperar más física de la que los datos contienen**, de modo que el criterio de éxito es acercarse a g_{exp} , no a -9.81 .

Se entrenaron las tres formulaciones con las tres arquitecturas de la sección 6.3 y cinco semillas distintas, en total 45 entrenamientos, con optimizador Adam, $\eta = 10^{-2}$, hasta 800 épocas y parada temprana sobre clips de validación completos.

8.2. Recuperación del parámetro físico

La tabla 6 recoge el resultado principal.

Formulación	Arquitectura	Parámetros	g recuperada	Error vs. -9.81
v1	simple (2)	7	$+0.00 \pm 0.00$	100.0 %
	media (4)	13	-1.21 ± 1.67	87.6 %
	tanh 32×32	1153	-2.77 ± 0.56	71.8 %
tau	simple (2)	7	-3.02 ± 4.14	69.2 %
	media (4)	13	-7.61 ± 0.39	22.5 %
	tanh 32×32	1153	-9.07 ± 0.28	7.6 %
tau_v0	simple (2)	9	-4.68 ± 4.30	52.3 %
	media (4)	17	-7.53 ± 0.57	23.3 %
	tanh 32×32	1185	-9.46 ± 0.33	3.8 %
<i>Referencia experimental</i> (ajuste por clip)			-9.48 ± 0.11	3.4 %

Cuadro 6: Mediana de la g recuperada ajustando una parábola a las predicciones de cada clip de prueba, en m/s^2 . Media y desviación estándar sobre cinco semillas, evaluadas siempre sobre clips que la red no vio durante el entrenamiento.

El resultado es inequívoco. Con la formulación original, la mejor de las tres redes se queda en -2.77 m/s^2 , un 72 % de error. Con la formulación corregida, la misma red alcanza $-9.46 \pm 0.33 \text{ m/s}^2$.

La comparación pertinente no es contra -9.81 sino contra la referencia experimental $g_{\text{exp}} = -9.48$, que es lo que el método clásico extrae de estos mismos datos: la discrepancia es entonces de **0.2 %**. La red reproduce la gravedad contenida en el conjunto de datos prácticamente sin sesgo; el 3.4 % restante frente al valor verdadero es una limitación del experimento, común a la red y al método clásico.

La figura 10 presenta el mismo resultado gráficamente y la figura 11 muestra las distribuciones completas: bajo **v1** las dos poblaciones están separadas, bajo **tau_v0** se superponen.




Figura 10: (a) Gravedad recuperada por formulación y arquitectura; la línea discontinua es el valor físico. (b) RMSE sobre clips no vistos, con las tres líneas base como referencia. Barras de error: desviación estándar sobre cinco semillas.




Figura 11: Distribución de la g estimada clip por clip para la red tanh 32×32 , en azul la de los datos experimentales y en color la de las predicciones. Al pasar de $v1$ a τ_{v0} las dos distribuciones dejan de estar separadas y se superponen.

La figura 12 es quizá la más clara de todo el informe. En la fila superior, la red bajo la formulación original produce la misma curva para los cuatro clips, con desajustes de hasta un metro. En la inferior, la misma arquitectura bajo la formulación corregida sigue la parábola de cada clip.




Figura 12: Cuatro clips de prueba con las predicciones de la red tanh 32×32 . Arriba, formulación $v1$: la red no puede distinguir un clip de otro y predice esencialmente la misma curva para todos. Abajo, formulación τ_{v0} : la red reproduce la trayectoria de cada clip.

8.3. Error de predicción y líneas base

Para que el RMSE signifique algo se comparó contra tres referencias, de la más débil a la más fuerte: el predictor constante que devuelve siempre la media; el modelo físico $\Delta y = v_0 \tau + \frac{1}{2} g \tau^2$ con una única g ajustada sobre los clips de entrenamiento, es decir, la ecuación de MRUV con un solo parámetro libre; y el ajuste parabólico independiente por clip, que usa el propio clip que evalúa y por tanto no es un predictor honesto, pero marca

el suelo de error alcanzable.

Modelo	RMSE [m]	MAE [m]	R^2
Predictor constante $\bar{y}$	0.5534	—	0.000
Red v1 , tanh 32×32	0.4970	0.4170	0.329
MRUV con g global (1 parámetro)	0.2020	0.0841	0.841
Red tau , tanh 32×32	0.1670	0.0984	0.898
Red tau_v0 , tanh 32×32	0.1420	0.0728	0.926
Ajuste por clip (oráculo, 3 parám./clip)	0.0401	0.0286	0.994
Suelo de ruido (residuo del ajuste)	0.0343	—	—

Cuadro 7: Error de predicción sobre clips no vistos, promediado sobre cinco semillas. Todas las cantidades en metros.

Tres observaciones.

El salto es de un factor 3.5. El RMSE baja de 0.497 a 0.142 m y el R^2 sube de 0.33 a 0.93. Bajo la formulación original las redes explicaban un tercio de la varianza; bajo la corregida explican el 93 %.

La red supera al modelo físico analítico. La ecuación de MRUV con g global alcanza RMSE = 0.202 m; la red llega a 0.142 m, un 30 % mejor con las mismas entradas. La razón más probable es que v_0 , estimado a partir de tres puntos ruidosos, lleva un sesgo sistemático que la red aprende a compensar y que la fórmula analítica no puede corregir. Este es el primer resultado del proyecto en el que la red aporta algo que el método clásico no da.

Aún queda margen. El oráculo por clip alcanza 0.040 m, cerca del suelo de ruido de 0.034 m. La diferencia con el 0.142 m de la red se explica porque el oráculo ajusta tres parámetros *por clip*, mientras que la red dispone únicamente de (τ, v_0) y no puede reproducir las desviaciones individuales de cada trayectoria.

8.4. El límite cambia de naturaleza

Hay un contraste en las tablas 6 y 7 que merece atención propia, porque constituye la confirmación más fuerte del diagnóstico de la sección 7.4.

Bajo la formulación **v1**, pasar de 7 a 1153 parámetros —un factor 165— apenas mejoraba nada: el RMSE bajaba de 0.537 a 0.497 m y la g seguía siendo inservible. Bajo **tau_v0**, la misma escalada lleva la g recuperada de -4.68 a -9.46 y el RMSE de 0.177 a 0.142 m.

Es decir: **con el problema mal planteado, la capacidad no importaba; con el problema bien planteado, la capacidad pasa a ser el factor decisivo.** Eso es exactamente lo que predice el análisis de identificabilidad. Cuando el límite es de información, ninguna arquitectura puede superarlo, porque la solución óptima —la media condicional— ya está al alcance de una red pequeña. Cuando el límite es de representación, una red mayor sí ayuda.

El fracaso de la red $1 \rightarrow 2 \rightarrow 1$ bajo **tau_v0** ($g = -4.68$, con una dispersión entre semillas de 4.30) tiene ahora una lectura distinta a la de la sección 7.5: dos unidades ReLU solo pueden formar una función lineal a trozos con dos quiebres, con la que no se aproxima

una parábola. Es una limitación genuina de capacidad, no un artefacto. La inestabilidad entre semillas es coherente con el fenómeno de ReLU muerta ya descrito.

La figura 13 resume las 45 corridas en un solo gráfico.




Figura 13: Error relativo en g frente al RMSE para las 45 corridas (3 formulaciones × 3 arquitecturas × 5 semillas). Las corridas con la formulación original se agrupan arriba a la derecha; solo la formulación **tau_v0** con la red tanh profunda baja del 5 % de error.

8.5. Síntesis

El supuesto del anteproyecto **se verifica**. Una red neuronal entrenada con datos experimentales de caída libre sí permite recuperar el modelo físico subyacente, con una discrepancia del 0.2 % respecto de lo que el método clásico extrae de los mismos datos.

Lo que hizo falta no fue una red mejor —son las mismas tres arquitecturas de la sección 6.3— ni más datos —son los mismos 609 clips— ni más entrenamiento. Hizo falta formular la pregunta de manera que tuviera respuesta.

9. Limitaciones del estudio

9.1. Limitaciones de la formulación inicial, ya corregidas

Las cuatro primeras son defectos de protocolo, y su corrección constituye el experimento de la sección 8. Se enumeran porque son el objeto de estudio de la primera mitad del informe, no porque sigan pendientes.

1. **No identificabilidad del mapeo $y = f(t)$.** Es la limitación principal, discutida en la sección 7.4. Los clips se concatenaron sin normalizar el origen temporal ni la altura inicial, de modo que la información necesaria para distinguir una trayectoria de otra no llegaba a la red. *Corregido* con la formulación $(\tau, v_0) \rightarrow \Delta y$ de la sección 8.1.

2. **Partición de validación por punto.** Al repartir los puntos individuales al azar, puntos de un mismo clip quedan a ambos lados de la partición. El error de validación mide entonces interpolación dentro de clips ya vistos y no generalización a un clip nuevo, por lo que sobreestima la capacidad del modelo (sección 3.4.2). *Corregido* con la partición por clip completo.
3. **Una sola semilla por configuración.** Sin repeticiones no era posible separar las diferencias reales entre arquitecturas de la dispersión por inicialización, que en el caso de la red $1 \rightarrow 2 \rightarrow 1$ es del mismo orden que las diferencias reportadas (sección 7.5). *Corregido* con cinco semillas por configuración.
4. **Ausencia de una línea base clásica.** No se comparaba contra el ajuste cuadrático directo por clip, que es el método convencional para este problema. *Corregido* con las tres referencias de la sección 8.3.

9.2. Limitaciones que permanecen

Las siguientes son propiedades del conjunto de datos y acotan lo que puede lograrse con él, con red o sin ella.

5. **Calidad de la digitalización.** La dispersión de 2.36 m/s^2 en la g experimental por clip y el escalonado visible en la figura 5(b) indican cuantización a nivel de píxel. El filtro de calidad de la sección 8.1 descarta los peores casos y reduce la dispersión a 1.82 m/s^2 , pero no elimina el ruido de fondo.
6. **Sesgo experimental en g .** El método clásico aplicado a estos datos da -9.43 m/s^2 , un 3.9 % por debajo del valor físico. Ese sesgo —probablemente de calibración de la escala espacial o de la velocidad de fotogramas— afecta por igual a la red y al ajuste clásico, y fija el techo de exactitud alcanzable con este conjunto.
7. **Duración de los clips.** Con 0.53 s de media, el término cuadrático de la ecuación (1) contribuye poco frente al ruido de medición, lo que hace intrínsecamente difícil estimar g a partir de un clip aislado.
8. **Estimación de v_0 .** Se obtiene de los tres primeros puntos de cada clip y arrastra el ruido de esas mediciones. Que la red supere al modelo analítico de MRUV (sección 8.3) sugiere que compensa un sesgo de esa estimación, pero no se comprobó de forma directa.

10. Conclusiones

1. Se construyó un conjunto de datos experimental propio de caída libre: 609 clips grabados a 60 Hz, 606 utilizables, 20 210 pares (t, y) digitalizados con *Tracker*. El conjunto contiene la física buscada, como demuestra el hecho de que un ajuste cuadrático clip por clip recupere g con mediana -9.38 m/s^2 , a un 4 % del valor esperado.
2. Se implementaron y entrenaron en PyTorch tres arquitecturas de red neuronal de complejidad y información de entrada crecientes, y se caracterizó su desempeño en función del número de épocas. Con ello se cumplieron los objetivos específicos relativos a la construcción, entrenamiento y estudio de redes neuronales.

3. **Con el planteamiento inicial, ninguna de las tres redes infiere el modelo físico.** Ajustando una parábola a sus predicciones clip por clip se obtiene g entre 0 y -3.6 m/s^2 , frente al -9.38 m/s^2 de los datos. En términos de predicción, mejoran solo un 18 % al predictor constante ($R^2 \approx 0.31$).
4. La causa es un defecto de planteamiento y no de las redes. Al agrupar 606 trayectorias con distinta altura inicial y distinto origen temporal bajo un único mapeo $y = f(t)$, el problema deja de ser identificable: la solución óptima del error cuadrático pasa a ser la media condicional $\mathbb{E}[y | t]$, cuyo coeficiente cuadrático es próximo a cero. Las redes convergen a esa solución, que es lo correcto dado el problema que se les planteó.
5. **Reformulado el problema, el supuesto del anteproyecto se verifica.** Refiriendo cada clip a su propio origen, con entradas (τ, v_0) y salida Δy , la red tanh profunda recupera $g = -9.46 \pm 0.33 \text{ m/s}^2$ sobre clips que no vio durante el entrenamiento. Frente al -9.48 m/s^2 que el método clásico extrae de esos mismos datos, la discrepancia es del 0.2 %. El R^2 pasa de 0.33 a 0.93 y el RMSE de 0.497 a 0.142 m.
6. Ese resultado se obtuvo con las *mismas* tres arquitecturas, los *mismos* 609 clips y sin más entrenamiento: lo único que cambió fue la formulación del problema y el protocolo de evaluación.
7. **El límite cambia de naturaleza al corregir el planteamiento.** Bajo la formulación inicial, multiplicar por 165 el número de parámetros no mejoraba la estimación de g ; bajo la corregida, la misma escalada la lleva de -4.68 a -9.46 m/s^2 . Cuando el límite es de información, ninguna arquitectura lo supera; cuando es de representación, la capacidad pasa a ser decisiva. Esta inversión es la confirmación más fuerte del diagnóstico.
8. En la formulación corregida la red **supera al modelo analítico**: RMSE de 0.142 m frente a 0.202 m de la ecuación de MRUV con una única g ajustada, con las mismas entradas. Es el primer punto del proyecto en que la red aporta algo que el método clásico no proporciona, verosíblemente por compensar el sesgo de la estimación de v_0 .
9. Un análisis anterior de estos mismos datos concluyó que las redes reproducían el parámetro físico con menos del 2 % de error, por haber comparado contra un ajuste cuadrático realizado sobre el conjunto agregado, cuyo coeficiente ($+0.35 \text{ m/s}^2$) no es la aceleración de la gravedad sino un artefacto de mezclar trayectorias incompatibles. La lección metodológica es general: en la validación de un modelo de aprendizaje automático contra una teoría física, el valor de referencia debe verificarse con el mismo rigor que el valor predicho.
10. Una red neuronal entrenada con MSE converge a la media condicional de los datos. Que esa media condicional coincida o no con la ley física depende enteramente de cómo se hayan estructurado las entradas. Este es el aprendizaje central del proyecto y la base sobre la que se plantea su continuación.

11. Trabajo futuro

Las correcciones de planteamiento y de protocolo que exigía el diagnóstico ya se aplicaron y son el contenido de la sección 8. Lo que sigue son las líneas que quedan abiertas,

ordenadas de la más inmediata a la más ambiciosa, y que constituyen la continuación natural hacia el EPS.

Cerrar la brecha con el oráculo. La red alcanza $\text{RMSE} = 0.142$ m frente a los 0.040 m del ajuste por clip. Parte de esa diferencia es irreducible —el oráculo dispone de tres parámetros por clip— pero conviene medir cuánta. Dos vías: predecir directamente los coeficientes (c_0, c_1, c_2) de cada clip en lugar de puntos sueltos, y estimar v_0 con más robustez (ajuste local en vez de tres puntos).

Diagnosticar el sesgo experimental. El método clásico da -9.43 m/s² sobre estos datos, un 3.9% por debajo del valor real. Antes de perseguir mejoras en el modelo conviene identificar si el sesgo viene de la calibración de la escala espacial, de la velocidad de fotogramas declarada o del arrastre del aire, y corregirlo en la toma de datos.

Mejorar la calidad de los datos. Grabar clips más largos o desde mayor altura, para que el término cuadrático domine sobre el ruido, y aumentar la resolución espacial o la frecuencia de muestreo. Con 0.53 s de media por clip, la señal cuadrática es débil frente a la cuantización de píxel.

Inspeccionar la red entrenada. El objetivo del anteproyecto incluía *estudiar la estructura interna* de la red, y hasta ahora esa estructura se ha sondeado solo por su salida. Con el problema ya bien planteado tiene sentido examinar los pesos de la red tanh y comprobar si alguna combinación de neuronas implementa de forma reconocible el término $\frac{1}{2}g\tau^2$.

Explorar el aprendizaje con restricciones físicas. Incorporar el residuo de la ecuación de movimiento a la función de coste (*physics-informed neural networks*) permitiría comparar cuánta física aporta la arquitectura frente a cuánta aporta la función de coste, y previsiblemente reducir la dispersión entre semillas.

Generalizar a otros marcos teóricos. Con el protocolo ya validado sobre la caída libre, extender el estudio a movimiento en dos dimensiones, a sistemas con fricción y a osciladores, que es el objetivo planteado para el EPS. El procedimiento de verificación desarrollado aquí —reformular hasta que el problema sea identificable, comparar contra una línea base clásica y estimar el parámetro físico caso por caso— es directamente transferible a esos sistemas.

12. Bibliografía

Referencias comentadas

Todo lo pertinente a teoría física fue tomado de Blatt [11]. La referencia estadística predeterminada, para regresión, mínimos cuadrados y métricas de error, es el libro de Triola [1]. La parte matemática — derivadas parciales y regla de la cadena — se consultó en el libro de cálculo de Zill [2]. El canal de YouTube DotCSV es una referencia audiovisual bastante completa en cuanto a redes neuronales se refiere [5, 6, 7, 8], y complementa la introducción de Antonio [3] y la documentación divulgativa de IBM [4]. Para consultas técnicas rápidas sobre funciones de activación se usó la página de Wikipedia correspondiente [9]. Las ayudas para entender el manejo de bibliotecas de aprendizaje profundo se

tomaron de Kapoor, Gulli y Pal [12] y, como documentación complementaria, del libro de Martínez [13]. La documentación de TensorFlow [10] se consultó durante la fase inicial, antes de la migración a PyTorch descrita en la sección 3.5.

Referencias

- [1] M. F. Triola, *Estadística*. Pearson Educación de México, S.A. de C.V., 2018.
- [2] D. G. Zill, *Cálculo con geometría analítica*. Grupo Editorial Iberoamérica, 1985.
- [3] J. Antonio, “Introducción a las redes neuronales: explicación completa en español,” 08 2023.
- [4] IBM, “¿qué son las redes neuronales? — ibm.”
- [5] C. Santana, “¿qué es una red neuronal? parte 1 : La neurona — dotcsv,” 03 2018.
- [6] C. Santana, “¿qué es una red neuronal? parte 2 : La red — dotcsv,” 05 2018.
- [7] C. Santana, “¿qué es una red neuronal? parte 3 : Backpropagation — dotcsv,” 10 2018.
- [8] C. Santana, “¿qué es una red neuronal? parte 3.5 : Las matemáticas de backpropagation — dotcsv,” 10 2018.
- [9] W. Contributors, “Activation function,” 11 2018.
- [10] Google Brain Team, “Por qué tensorflow,” 2014.
- [11] F. J. Blatt, *Fundamentos de Física*. Prentice-Hall Hispanoamericana, S.A., 1991.
- [12] A. Kapoor, A. Gulli, and S. Pal, *Deep Learning with TensorFlow and Keras*. Packt Publishing Ltd., 2022.
- [13] J. Martínez, *TensorFlow 2.0 Computer Vision Cookbook*. Packt Publishing Ltd., 2021.